Linguistique de corpus (TALA332A)
Outils et Méthodes pour corpus (TALA332B)

Projet de fin de semestre (S1)

Question 1 :

Les textes ont été téléchargés à partir du site de l'ABU. Pour vérifier l'encodage de ceux-ci, nous avons ouvert le terminal et utilisé la commande « file » qui permet d'afficher l'encodage du texte. Les fichiers ont été encodés en LATIN1 ; nous avons donc converti les textes en UTF-8 grâce à l'enchainement de commandes suivant : `iconv -f LATIN1 -t UTF-8 nomdufichiersource.txt -o nomdufichierconverti2.txt`

Avant :

```
--- ATTENTION : CONSERVEZ CETTE LICENCE SI VOUS REDISTRIBUEZ CE FICHIER ---
License ABU
-=-=-=-=-=-
Version 1.1, Aout 1999

Copyright (C) 1999 Association de Bibliophiles Universels
   http://abu.cnam.fr/
   abu@cnam.fr

La base de textes de l'Association des Bibliophiles Universels (ABU)
est une oeuvre de compilation, elle peut ?tre copi?e, diffus?e et
modifi?e dans les conditions suivantes :

1.  Toute copie ? des fins priv?es, ? des fins d'illustration de l'enseignement
    ou de recherche scientifique est autoris?e.
```

Après :

```
myriambenhadj@MacBook-Air-de-Myriam Corpus linguistique % iconv -f LATIN1 macint
osh -t UTF-8 Memoires_dun_touriste.txt -o Memoires_dun_touriste2.txt
iconv: macintosh: No such file or directory
iconv: -t: No such file or directory
iconv: UTF-8: No such file or directory
--- ATTENTION : CONSERVEZ CETTE LICENCE SI VOUS REDISTRIBUEZ CE FICHIER ---
License ABU
-=-=-=-=-=-
Version 1.1, Aout 1999

Copyright (C) 1999 Association de Bibliophiles Universels
   http://abu.cnam.fr/
   abu@cnam.fr

La base de textes de l'Association des Bibliophiles Universels (ABU)
est une oeuvre de compilation, elle peut être copiée, diffusée et
modifiée dans les conditions suivantes :

1.  Toute copie à des fins privées, à des fins d'illustration de l'enseignement
    ou de recherche scientifique est autorisée.
```

Après conversion des deux fichiers, nous allons élaborer l'arborescence de notre dossier dans le but de rendre toutes les données de notre projet. Pour ce faire, nous allons créer un dossier parent que nous nommerons « Traitement corpus Python » dans lequel nous créerons un sous-dossier « Corpus linguistique » au sein duquel nous ajouterons deux autres sous-dossiers, un premier sous-dossier « METADATA » et un deuxième « TEXTES ». Le sous-dossier METADATA contiendra tous les fichiers contenant les métadonnées de chaque texte. Le sous-dossier TEXTES contiendra quant à lui les textes bruts, sans leurs métadonnées :

```
.
└── Corpus linguistique
    ├── METADATA
    │   ├── Memoires_dun_touriste_META.txt
    │   ├── le_tour_du_monde_META.txt
    │   └── les_revoltes_de_la_bounty_METAcopie.txt
    └── TEXTES
        ├── Memoires_dun_touriste_texte.txt
        ├── le_tour_du_monde_texte.txt
        └── les_revoltes_de_La_bounty_texte.txt

4 directories, 6 files
myriambenhadj@MacBook-Air-de-Myriam Traitement de corpus Python %
```

Les fichiers de chaque question seront toujours précédés d'un des arguments suivants afin de pouvoir les distinguer : « infinitive » pour la question 2, « any_verbs » pour la question 3 et « segment » pour la question 4;

Question 2

Pour filtrer automatiquement le corpus avec le contenu du lexique afin d'identifier pour chaque document le texte toutes ses occurrences de formes verbales à l'infinitif nous avons fait appel aux dictionnaires Python. Une fois les programmes exécutés, les résultats ont été rangés dans un tableur Excel pour une meilleure visualisation de ceux-ci.

Nous allons tout d'abord comparer les résultats des fichiers **le_tour_du_monde.txt** avec ceux de l'autre fichier **memoires_dun_touriste.txt** Les titres nous donnent déjà un indice sur l'histoire, ce qui nous permet d'anticiper en amont les types de verbes ainsi que les notions que l'on pourrait retrouver au sein des résultats. Nous comptons un bon nombre de verbes de mouvement : accompagner, aller, arriver, débarquer, transporter, traverser, venir, visiter, voyager, suivre, partir, descendre, embarquer, entrer, passer, marcher, monter, parcourir, promener, traverser. Notons que certains verbes peuvent exprimer des sens différents en fonction de leur contexte d'occurrence. Le verbe « passer » à titre d'exemple, peut exprimer à la fois un mouvement dans l'espace : « Passer le pont de l'Alma. » mais aussi un mouvement plus abstrait qui se produirait dans le temps : « Passer du temps chez un ami. ». Nous comptons également des verbes de perception, verbes liés aux cinq sens : entendre, voir, apercevoir ainsi que des verbes d'action : chercher, courir, demander, dire, empêcher, faire, jouer, parler, prendre, trouver, laisser, perdre. Tous ces verbes décrivent un contexte de déplacement et de voyage, qui demande beaucoup de mouvements, de perception et d'action au sujet. L'oeuvre de Stendhal « Les mémoires d'un touriste » constitue en réalité le journal de bord des voyages de Stendhal. L'oeuvre de Jules Verne « Le tour du monde en quatre-vingts jours » quant à elle, raconte l'histoire de Phileas Fogg et de son domestique qui feront un tour du monde en quatre-vingts jours. Ce voyage est réalisé en plein contexte de révolution industrielle et technique, notamment avec le développement de véhicules à vapeur (bateau, voiture) ainsi que des chemins de fer engendrant la démocratisation des voyages sur de longues distances en peu de temps. Tout cela explique ainsi la présence de verbes de mouvement, de perception et d'action.

Nous allons maintenant comparer les résultats des fichiers **memoires_dun_touriste.txt** et **les_revoltes_de_La_bounty.txt** entre eux. Un

bon nombre de verbes de mouvement sont présents : accompagner, aller, débarquer, diriger, transporter, suivre, partir, descendre, embarquer, entrer, rentrer, transporter, passer, partir. D'autres verbes d'action assez durs et violents sont présents dans ce même texte : exécuter, obéir, emporter, porter, supporter, menacer, résister, sacrifier, sauter supporter, venger. Nous notons également la présence de verbes d'état et d'action : voir, observer, paraître parler. La notion de déplacement est une notion assez présente dans les deux textes. Nous notons que les verbes de mouvements relevés dans cette analyse dénotent d'une certaine violence et de dureté. Un vocabulaire de mouvement que l'on retrouverait dans des contextes d'affrontements, de combat, de révolte et de manifestation. Ce qui coïncide parfaitement avec le nom de l'oeuvre « Les révoltés de la Bounty », qui évoque le naufrage d'un navire nommé « la Bounty ». L'histoire se passe au XVIII ème siècle, en 1787, très peu de temps avant la Révolution Française, dans un contexte de volonté de découverte et de conquête chez les Européens. Nous pouvons citer par exemple la colonisation française des Antilles mais aussi des Amériques (la Nouvelle-France, « Amérique du Nord française ») ou encore la Campagne d'Égypte de Napoléon en 1798.

Enfin, nous allons comparer entre eux, les résultats des deux textes du même auteur. Nous comptons, comme pour les textes précédents, un bon nombre de verbes de mouvement : accompagner, aller, débarquer, diriger, transporter, suivre, partir, descendre, embarquer, entrer, rentrer, transporter, passer, dépasser, partir, parvenir, revenir, arriver. Nous notons également des verbes d'action itératifs tels que « refaire », « reprendre » ainsi que leurs formes canoniques « faire » et « prendre ». Nous notons également des verbes d'action qui relèvent d'une sémantique assez violente : exécuter, obéir, perdre, sacrifie, sauter, venger, ainsi que des verbes d'action qui dénotent d'un déplacement précipité dans un espace grand ou petit : chercher, courir, dire, parler trouver, laisser.

Nous retrouvons également des verbes un peu moins violents tels que « convenir », « prévenir » ou « subvenir ». Un voyage peut être violent et dangereux car un voyageur n'est jamais à l'abris de tout un tas de dangers au cours de son périple ; d'où les occurrences de verbes d'action qui dénotent d'une certaine violence. Une révolte est un évènement violent, les révolutionnaires sont le plus souvent amenés à combattre et donc à mener des actions violentes. Un voyage c'est également un déplacement, tout comme une révolte qui pousse les révolutionnaires à se déplacer pour aller combattre ou affronter l'ennemi. Nous retrouvons ainsi la notion du danger et du déplacement au sein des deux textes dont l'un évoque le voyage et l'autre la révolte.

Question 3 :

Nous comparerons les différentes formes verbales contenues dans les fichiers **le_tour_du_monde.txt** et **memoires_dun_touriste.txt.** Nous constatons que les verbes de mouvement et de perception se déclinent sous plusieurs formes verbales. Nous constatons que l'imparfait, le passé simple et le présent de l'indicatif sont les temps qui dominent les deux textes, les temps les plus usités pour la narration d'une histoire : apercevait - VCJ:sg

apercevais VCJ:sg
apercevions VCJ:pl
approchait VCJ-sg
descendrais VCJ:sg
descend VCJ:sg
descendrais VCJ:sg
arriva VCJ:sg
arrivait VCJ:sg
arrive VCJ:sg
arrivera VCJ:sg
arriverait VCJ:sg

allaient VCJ:pl
alliez VCJ:pl
allions VCJ:pl
voyageait VCJ:sg
voyageais VCJ:sg

Nous notons la présence de nombreux adverbes. Pour rappel, un adverbe est un élément qui vient ajouter une détermination à un verbe pour apporter plus de détails sur la manière dont est faite l'action. Nous retrouvons parfois certains verbes de mouvements seulement sous forme d'adverbe. Le fichier « le_tour_du_monde.txt » semble contenir plus d'adverbes mais les deux fichiers semblent plutôt descriptifs dans leurs occurrences :

apercevant VNCNT
arrivant VNCNT
allant VNCNT
arrivant VNCNT
approchant VNCNT
reculant VNCNT
roulant VNCNT

Le fichier le_tour_du_monde.txt semble plus descriptif car il affiche beaucoup plus d'adverbes et de verbes à la troisième personne du singulier. Le narrateur est certainement externe à l'histoire. Il vient décrire les actions de chaque personnage de l'oeuvre. Le fichier memoires_dun_touriste.txt contient moins d'adverbes et semble plus narratif que descriptif, avec moins d'adverbes et de verbes conjugués à la troisième personne du singulier.

Nous comparons maintenant les résultats des fichiers **le_tour_du_monde.txt** et **les_revoltes_de_La_bounty.txt**. Tout comme pour les deux textes précédents,

les temps qui dominent les fichiers sont l'imparfait, le passé simple ainsi que le présent de l'indicatif, qui constituent les temps les plus usités en littérature pour narrer un récit. De nos jour, l'imparfait tend à remplacer le passé simple. Nous notons. Une nouvelle fois la présence de verbes de mouvement, de perception et d'état sous diverses formes verbales : descendit, disparaissait, disparut, entendit, affaiblis.

Nous notons également la présence d'adverbes, qui sont plus nombreux dans le fichier memoires_dun_touriste.txt et beaucoup moins nombreux dans le fichier la_revolte_de_La_Bounty.txt. Le fichier la_revolte_de_La_Bounty.txt a l'air de contenir plus de dialogues et semble moins dans la description des actions, comparé au fichier les_memoires_dun_touriste.txt, qui semble beaucoup plus descriptif puisque celui-ci constitue les notes de voyage de l'auteur. Le narrateur serait donc interne à l'histoire. Il devait certainement y décrire ses mouvements, les paysages etc. Contrairement aux données extraites de l'œuvre *Les révoltés de la Bounty* qui semble laisser place aux dialogues entre les personnages de l'œuvre. L'auteur est certainement externe à l'histoire voire omniscient. Nous pouvons noter les adverbes suivants : arrivant, approchant, entendant, disant, voyant, souffrant, dirigeant.

Enfin, nous allons comparer les deux textes du même auteur entre eux. Tous comme les autres fichiers précédemment analysés, les temps dominant les fichers le_tour_du_monde.txt et les_revoltes_de_La_bounty sont le passé simple, l'imparfait ainsi que le présent de l'indicatif mais nous notons également du futur. N'ayant pas les contextes d'occurrences de chaque mot, il peut être compliqué parfois de savoir s'il s'agit de verbes au futur ou de verbes au conditionnel passé. Tout un tas de verbes de mouvement, de perception et d'état existent sous diverses formes verbales dans le fichier le_tour_du_monde.txt : arriva, arrivait, arrivera, arriverait, atteint, atteignait,

atteint, cours, courut, grimpait, parcourut, promenait, suivait, suivis, suis, suit, suivrai. Tout comme dans *Les révoltés de la Bounty*, le narrateur semble être externe à l'histoire dans *Le tour du monde en quatre-vingts jours*. L'œuvre doit certainement contenir beaucoup de dialogues. Il semble plus descriptif que *Les révoltés de la Bounty* puisque le récit narre les aventures du personnage qui voyage aux quatre coins du globe. Ainsi, le narrateur est amené à décrire les actions de son personnage, ce qu'il voit etc. Le récit semble plus tranquille et long que *Les révoltés de la Bounty* au sein duquel on y décrirait plutôt des scènes de combat, des scènes plus ou moins violentes et rapides. *Les révoltés de la Bounty* semble contenir plusieurs personnages principaux, du moins, plus de personnages principaux que *Le tour du monde en quatre-vingts jours*. Le tour du monde en quatre-vingts jours semble plus descriptif et précis peut-être parce qu'il ne décrit pas énormément de scènes de groupe, contrairement *Aux révoltés de la Bounty* qui décrit des scènes de combat, d'altercations et donc des actions le plus souvent menées en groupe. Nous constatons également que le fichier le_tour_du_monde.txt compte un grand nombre d'adverbes, peut-être parce qu'il est justement plus descriptif que celui *Des révoltés de la Bounty* : abaissant, aidant, apercevant, arrivant, appuyant, attendant, criant, diminuant, venant, voyant.

Il y a effectivement une différence entre les verbes à l'infinitif relevés dans la deuxième question. De plus, certains verbes de mouvement, de perception ou d'état, qui n'apparaissaient pas dans les fichiers à l'infinitif, apparaissent sous d'autres formes verbales.

<u>Question 4 :</u>

Comme pour les autres questions, nous allons tout d'abord comparer les résultats pour les fichiers **le_tour_du_monde.txt** avec l'autre fichier **memoires_dun_touriste.txt**. Le fichier memoires_dun_touriste.txt contient

plus de structures à la première personne du singulier ainsi qu'à la première personne personne du pluriel tandis que le fichier le_tour_du_monde.txt contient beaucoup plus d'occurrences à la troisième personne du singulier et du pluriel. Le narrateur semble plutôt interne dans les résultats du fichier memoires_dun_touriste.txt tandis qu'il semble externe à l'histoire dans les résultats du fichier le_tour_du_monde.txt. Les structures syntaxiques nous permettent de mieux interpréter les occurrences car elles nous permettent de visualiser les contextes d'occurrences.

Nous allons maintenant comparer et analyser les structures syntaxiques contenues au sein des fichiers **memoires_dun_touriste.txt** et **les_revoltes_de_La_bounty.txt**. Les résultats du fichier les_revoltes_de_la_bounty.txt sont maigres en terme de données. Les résultats du fichier les_revoltes_de_La_bounty.txt ne contiennent que des des participes passés dont la plupart des auxiliaires sont conjugués à l'imparfait. Il s'agit pour la plupart de verbes d'état et de perception. Les phrases sont à la deuxième et troisième personne du singulier ainsi qu'à la deuxième et troisième personne du pluriel. Comme nous l'avions précédemment vu, le narrateur semble externe à l'histoire. Nous retrouvons également au sein des fichiers de l'œuvre *Les révoltés de la Bounty* des occurrences de mots brutaux puisque l'œuvre semble décrire des scènes de combat, des actions plus ou moins violentes. Nous avons par exemple des phrases telles que « il est mort. », « tu seras pendu » ou encore « il fut surpris ». Le fichier contentant les données de l'œuvre *Mémoire d'un touriste,* contient de nombreuses occurrences de verbes conjugués à la première personne du singulier ainsi qu'à la troisième personne du singulier. Comme nous l'avions vu dans les questions précédentes, le narrateur semble interne à l'histoire. Nous notons la présence de verbes de perception « j'ai vu », « j'ai entendu », « j'ai senti », le narrateur décrit ses sentiments ainsi que ses ressentis. Il convient de noter que les occurrences

contenues dans le fichier memoires_dun_touriste.txt sont majoritairement à la première personne du singulier.

Enfin, nous allons comparer les deux textes du même auteur entre eux. Le fichier contenant les résultats de l'analyse des structures syntaxiques extraites de l'œuvre *Le tour du monde en quatre-vingts jours* contient de nombreuses occurrences à la troisième personne du singulier féminin et masculin ainsi qu'à la troisième personne du pluriel féminin et masculin. Ce qui nous confirme encore une fois que l'auteur semble externe à l'histoire, puisque les occurrences des première et deuxième personnes du singulier se font plus rare. Tout comme pour les occurrences de formes verbales diverses, les occurrences de structures syntaxiques nous permet de mieux cerner les contextes, puisque certains verbes peuvent avoir les mêmes terminaisons peut importe le pronom : « avais » peut être conjugué avec le pronom je ou tu par exemple, ce qui était un peu compliqué à identifier au départ. Le sens de certains verbes peut varier en fonction de leur structure syntaxique. Par exemple le verbe « entendre » peut désigner le fait d'être d'accord avec quelqu'un ou encore le fait d'apprécier quelqu'un : « Ils se sont entendus sur la décision. », « Ils s'entendent bien. ». Ainsi, la structure « s'être entendus » n'est pas suffisante sémantiquement parlant pour savoir s'il s'agit du verbe de perception « entendre » ou des expressions qui prennent le sens d'« être d'accord avec quelqu'un » ou d'« apprécier quelqu'un ». Les structures syntaxiques nous permettent tout de même, comme pour les autres résultats, de mieux distinguer la position du narrateur (externe, interne ou omniscient) que dans les résultats obtenus dans les questions précédentes.

Difficultés rencontrées :

Question 2 :

- Débarrasser les mots des articles définis et indéfinis, des apostrophes, des traits d'union et autres ponctuations.
- Représenter la structure du résultat. Nous avons donc décidé de faire trois colonnes : une colonne mot, étiquettes et le nb d'occurrences
- Utiliser un dictionnaire dans un dictionnaire et donc un dictionnaire de mots par rapport au tag.

Question 3 :

- Rendre la fonction de détermination des tags dans le texte plus génériques.
- Gérer les cas de mots polysémiques en fonction des contextes (tag).
- Générer les bonnes étiquettes pour tous les verbes. Certains noms communs étaient associés à des étiquettes verbales.
- Fusionner deux fichiers texte (fonction merge result) pour implémenter la comparaison des textes entre eux.

Question 4 :

- Notions de copier une liste dynamique (liste qu'on modifie et dont le nombre va augmenter ou diminuer) qui correspond au fait d'ajouter une liste dans une liste.
- Copier la lise avec « deep copy » pour contrer la dynamisme de la liste.
- Déterminer que le segment soit valide : le premier élément va avoir un tag en particulier et il va vérifier le tag et le compteur. On parle d'algorithme génétique.

Ressources :

- Atelier de programmation, Kyriakoglou Revekka, 2023, INALCO
- Cours de Linguistique de corpus Outils et Méthodes pour corpus (TALA332B) Paroubek Patrick, 2023, INALCO

- Regeks (import du module regeks, pour pouvoir nettoyer les mots pour le process de tokénisation à l'aide du split.() de regeks).
- Chat GPT (pour enlever le premier élément d'une liste. Celui-ci conseille d'utiliser pop(0)).
- W3school.com, rubrique Python